

Comparar el funcionamiento del Algoritmo Decision Tree (DT) y el modelo de ensamble Random Forest (RF)

Objetivos:

1. Implementar el algoritmo DT.
2. Comparar el funcionamiento del algoritmo DT implementado con el modelo de ensamble RF desde el punto de vista del rendimiento de ambos modelos en problemas de clasificación.
3. Elaborar un informe completo en base a las pruebas realizadas.

Descripción del problema:

Este trabajo consiste en implementar los algoritmos DT y RF que, dado un dataset, permitan evaluar y comparar el rendimiento de ambos modelos. La idea básica es definir los modelos que tomen los datos, de diferentes tipos, de los atributos del dataset indicado por la cátedra y devuelva los resultados de clasificación tanto para el algoritmo DT como para el algoritmo RF. Adicionalmente, se deberán comprobar diferentes métricas de rendimiento que se logra con ambos modelos al cambiar la parametrización con los que se evaluarán los datos de prueba. La implementación deberá tener una interfaz amigable que permita al usuario correr pruebas fácilmente y observar los resultados obtenidos. **Aclaración:** El algoritmo DT deberá ser íntegramente desarrollado por el equipo, para el algoritmo RF se podrá utilizar un modelo de la librería Scikit-learn.

Decision Tree

Decision tree learning is one of the most widely used techniques for classification. Its classification accuracy is competitive with other learning methods, and it is very efficient. The learned classification model is represented as a tree, called a decision tree. The techniques presented in this section are based on the C4.5 system from Quinlan¹.

Random Forest

Random forests are a combination of tree predictors such that each tree depends on the values of a random vector sampled independently and with the same distribution for all trees in the forest. The generalization error for forests converges a.s. to a limit as the number of trees in the forest becomes large. The generalization error of a forest of tree classifiers depends on the strength of the individual trees in the forest and the correlation between them².

Se deberá entregar:

- Código fuente (que incluya documentación interna) que corra en la plataforma colaborativa Google Colab.
- Informe completo (digital) del desarrollo del trabajo que contenga:
 - Introducción.
 - Breve descripción de los algoritmos desarrollados.
 - Descripción de la solución implementada (explicando los problemas encontrados).
 - Simulaciones realizadas y resultados obtenidos.
 - Conclusiones.
 - Referencias.

Consideraciones adicionales:

- El notebook deberá contar con una interfaz de usuario amigable que permitan la total operabilidad de la aplicación.
- La cátedra definirá fechas parciales de entrega, siguiendo una metodología de desarrollo ágil.
- Se deberá utilizar la herramienta de seguimiento de proyectos Trello (la misma será revisada por la cátedra).
- El informe del trabajo deberá seguir el formato de LNCS (Lecture Notes in Computer Science) de Springer Verlag. Se pueden descargar las plantillas de: <http://preview.springer.com/gp/computer-science/lncs/conference-proceedings-guidelines> en esa página se encuentra, además de las plantillas, una guía para dar formato al informe. El mismo no deberá exceder las 12 carillas.
- Para la nota final del Informe se tendrán en cuenta aspectos como: prolijidad, redacción y ortografía.
- La información de cada fuente utilizada deberá ser citada. En caso que la referencia no coincida con el desarrollo o haya algún tipo de plagio, el trabajo práctico será automáticamente **desaprobado sin derecho a recuperatorio**.
- Sobre el uso de IA:

Condiciones generales:

Fecha límite de entrega	☐	11/11/2026 a las 23:59 hs. (*)
Fecha de coloquio grupal	☐	A convenir con los alumnos.
Calificación	☐	Promedio ponderado de informe, programa y coloquio.

(*) Luego de esta fecha y hora se aceptarán los trabajos hasta el 18/11/2026, pero sin la posibilidad de recuperatorio.

¹ Liu, Bing. Web Data Mining (Exploring Hyperlinks, Contents and Usage Data) (p. 67). Springer. Second Edition

² Breiman, L. Random Forests. Machine Learning 45, 5–32 (2001).