Estudio comparativo del rendimiento de un árbol de decisión C4.5 propio y del modelo de ensamble Random Forest en problemas de clasificación

Laura Cornaló Bassan[1 [00000]], Matías Fernandez[1 [24282]], Mariano Insaurralde[1 [24684]], Philippe Maurel[1 [25613]], y Franco Sanchez[1 [27310]]

Universidad Tecnológica Nacional, Facultad Regional de Resistencia
Ingeniería en Sistemas de Información
{correo1,correo2,correo3,correo4,correo5}@gmail.com

Resumen Se compara un árbol de decisión propio basado en C4.5 con Random Forest de scikit-learn sobre problemas de clasificación con atributos categóricos, numéricos y mixtos. Se utiliza un protocolo común con particiones estratificadas, selección interna por validación y evaluación final reservada. Se estudian métricas por clase, tiempos, sensibilidad a parámetros y valores ausentes adicionales. Los experimentos distinguen los faltantes naturales de Cleveland de las máscaras artificiales y mantienen las transformaciones dentro del entrenamiento. Los resultados se generan a partir de las mismas tablas que utiliza el entorno interactivo, con semillas y parámetros registrados. La comparación describe las condiciones medidas y sus limitaciones; no establece una superioridad general de un algoritmo.

Palabras clave: Árbol de decisión · C4.5 · Random Forest · Clasificación

1 Introducción

Un clasificador automático asigna una clase a cada caso a partir de sus características. Los árboles de decisión producen un modelo legible, en el que cada camino de la raíz a una hoja equivale a una regla [3]. Random Forest combina muchos árboles para reducir la dependencia de una sola estructura, a cambio de más cómputo y de una decisión que ya no se sigue en un único camino [1]. C4.5 elige cada pregunta con un criterio orientado a separar las clases y admite atributos numéricos y categóricos [3]. Ninguno de los dos enfoques domina al otro en general: la elección depende del problema, de la métrica que se priorice y del costo que se acepte pagar.

Este trabajo compara una implementación propia de C4.5 con el Random Forest de scikit-learn [5] sobre tres conjuntos de datos de atributos categóricos, continuos y mixtos. La comparación usa las mismas particiones, las mismas métricas y las mismas condiciones de evaluación. Con esquemas de evaluación

distintos, una diferencia de rendimiento puede reflejar la forma de medir y no el algoritmo. El objetivo es determinar en qué condiciones conviene cada uno, atendiendo a la tasa de acierto (proporción de predicciones correctas), la estabilidad de las predicciones ante cambios de semilla, el tiempo de cómputo y la interpretabilidad.

Las contribuciones son una implementación propia de C4.5 con decisiones explícitas sobre la construcción, el criterio de división y el control del crecimiento; un protocolo común de evaluación; y un análisis comparativo de esos cuatro aspectos.

El documento describe primero los fundamentos de ambos modelos, luego la implementación, después los experimentos y cierra con las conclusiones.

2 Fundamentos teóricos

2.1 Árboles de decisión y C4.5

C4.5 construye un árbol de decisión de forma recursiva [3]. En cada nodo elige la pregunta sobre un atributo que mejor separa las clases y repite el procedimiento en los subconjuntos resultantes. La entropía mide la impureza de un nodo a partir de la distribución de sus clases. Si D es el conjunto de casos, C el conjunto de clases y p_c la proporción de casos de la clase c, medida por masa cuando los pesos no son unitarios, la entropía se define en la ecuación (1):

$$H(D) = -\sum_{c \in C} p_c \log_2 p_c. \tag{1}$$

La entropía vale cero cuando todos los casos pertenecen a una misma clase y alcanza su máximo cuando las clases están equilibradas.

Una pregunta sobre un atributo A divide D en v subconjuntos D_j, con masas W_j, y W es la masa de D. La ganancia de información es la reducción de entropía que produce esa división, ecuación (2), donde la suma ponderada representa la impureza que queda en las ramas. Cuanto mayor es la ganancia, más puras quedan las ramas, y una ganancia nula indica que la partición no reduce la impureza.

$$\mathrm{Gain}(D, A) = H(D) - \sum_{j=1}^{v} \frac{W_j}{W} H(D_j). \tag{2}$$

La ganancia favorece a los atributos con muchos valores distintos, porque fragmentar el conjunto reduce la impureza casi por construcción. C4.5 atenúa ese efecto con la información de la partición, ecuación (3), que mide cuánto fragmenta el atributo. La tasa de ganancia, ecuación (4), es el cociente entre ambas magnitudes; un atributo que fragmenta demasiado queda penalizado. Si la partición no produce al menos dos ramas conocidas de masa positiva, el atributo

no se considera candidato.

$$\text{SplitInfo}(D, A) = -\sum_{j=1}^{v} \frac{W_j}{W} \log_2 \frac{W_j}{W}, \tag{3}$$

$$\text{GainRatio}(D, A) = \frac{\text{Gain}(D, A)}{\text{SplitInfo}(D, A)}. \tag{4}$$

Los atributos numéricos requieren un tratamiento distinto. En cada nodo se ordenan los valores observados, operación de costo $O(|D| \log |D|)$, y se examinan los $r - 1$ cortes entre valores consecutivos; cada corte separa los casos con $A \leq t$ de los que tienen $A > t$. Se conserva el corte con la mayor tasa de ganancia. El umbral es un valor observado y se elige en cada nodo, sin discretización global. Un atributo numérico puede reutilizarse en niveles inferiores, mientras que un atributo categórico se descarta después de usarse [3].

Con valores faltantes, sea W_K la masa de los casos con valor conocido para el atributo y W_U la de los que no lo tienen. La ganancia se calcula solo sobre el subconjunto D_K de casos conocidos y se escala por la fracción W_K/W, ecuación (5). La información de la partición agrega la masa faltante W_U como una rama de cálculo, aunque no origine una rama del árbol. La tasa de ganancia ajustada es el cociente entre la ganancia ajustada y esa información de la partición. En el entrenamiento, un caso faltante se envía a todas las ramas y su peso se reparte según $q_j = W_j/W_K$, ecuación (6); en la predicción, las probabilidades de las ramas se combinan con esas mismas proporciones [3].

$$\text{Gain}^*(D, A) = \frac{W_K}{W} \left[H(D_K) - \sum_j \frac{W_j}{W_K} H(D_j) \right], \tag{5}$$

$$q_j = \frac{W_j}{W_K}. \tag{6}$$

Este mecanismo es propio de C4.5.

Un árbol que crece sin restricciones puede ajustarse a rasgos particulares del conjunto de entrenamiento y perder capacidad sobre casos nuevos. La prepoda detiene el crecimiento durante la construcción; la pospoda elimina subárboles después de construir el árbol completo. El C4.5 original emplea pospoda pesimista, mientras que este trabajo aplica solo prepoda y no implementa poda de reglas [3]. La construcción es codiciosa: cada división se elige con la información disponible en el nodo y no se revisa después, de modo que la prepoda puede detener el crecimiento antes de lo conveniente.

2.2 Random Forest

Random Forest combina B árboles de decisión construidos con perturbaciones aleatorias [1]. Cada árbol se entrena con una muestra del mismo tamaño que el conjunto original, obtenida con reemplazo, y en cada división evalúa solo un subconjunto aleatorio de los atributos disponibles. Los árboles crecen sin poda

y la predicción combina sus respuestas por voto mayoritario o por promedio de probabilidades. Esa doble fuente de aleatoriedad reduce la dependencia de una sola estructura y la correlación entre los árboles.

Breiman muestra que el error de generalización depende de la fuerza de los árboles y de su correlación: árboles fuertes y poco correlacionados tienden a reducir el error [1]. La fuerza resume la separación media entre la clase correcta y las alternativas, y la correlación mide cuánto se parecen las respuestas de dos árboles. El análisis de este trabajo es empírico y no usa esa caracterización para calcular el error. En este trabajo se usa el clasificador de bosques aleatorios de scikit-learn, que promedia las probabilidades de las hojas y elige la clase de mayor valor; su configuración se detalla en la sección experimental [5].

3 Breve descripción de los algoritmos desarrollados

3.1 C4.5

El Algoritmo 1 resume la construcción del árbol. El procedimiento recibe el conjunto de casos, el conjunto de atributos disponibles $\mathcal{A}$, la profundidad d, los cuatro controles de crecimiento y devuelve un nodo. La masa de un nodo es la suma de los pesos de sus casos, de modo que los casos repartidos por valores faltantes no cuentan como filas completas. Las paradas estructurales se evalúan antes de elegir la división; la comparación con el umbral de ganancia y con la tasa mínima se aplica después, y es estricta: si el valor es menor, el crecimiento se detiene; la igualdad permite dividir.

Algoritmo 1 Construcción recursiva de un árbol C4.5

```
Calcular la masa por clase y elegir la clase mayoritaria.
si clase única, A vacío, profundidad máxima o masa mínima entonces
    devolver hoja con la clase mayoritaria.
fin si
para cada atributo a ∈ A hacer
    Evaluar sus divisiones y conservar la mayor tasa de ganancia ajustada.
fin para
si no hay candidato o no se alcanzan los mínimos entonces
    devolver hoja con la clase mayoritaria.
fin si
Crear el nodo con el atributo, el umbral o las ramas, y las proporciones.
para cada rama hacer
    Repartir los faltantes y construir el hijo con d + 1.
fin para
devolver el nodo.
```

Los empates se resuelven por el orden de los atributos y, entre cortes numéricos del mismo atributo, por el menor umbral. Un atributo categórico se elimina del conjunto disponible después de usarse; uno numérico se conserva, porque

los subconjuntos resultantes admiten nuevos cortes. En la predicción, un valor conocido sigue una sola rama; un valor faltante combina las distribuciones de todas las ramas con las proporciones aprendidas, y una categoría no vista usa las frecuencias locales del nodo alcanzado. La clase final es la de mayor probabilidad y los empates se resuelven con la primera clase observada en el entrenamiento.

3.2 Random Forest

La implementación de Random Forest usa el clasificador de bosques aleatorios de scikit-learn [5]. Los atributos categóricos se transforman en indicadores binarios aprendidos en entrenamiento. Antes de codificarlos, los valores ausentes se completan con la moda de su columna; las medidas numéricas utilizan la mediana. Ambas estadísticas se calculan únicamente con el bloque utilizado para aprender, sin eliminar casos ni consultar las respuestas de prueba [4].

4 Descripción de la solución implementada

4.1 Arquitectura y protocolo de evaluación

La solución se organiza en tres capas: preparación de los datos, modelos y evaluación. La preparación carga el conjunto de datos, deduce el tipo de cada atributo y construye una partición estratificada con el 80 % de los casos para entrenamiento y el 20 % para prueba, con una semilla fija de 42. Ambos modelos usan las mismas particiones y las mismas métricas, y ninguno accede al conjunto de prueba durante el entrenamiento. C4.5 admite valores faltantes y categorías nativas. Random Forest completa sus faltantes con la mediana numérica o la moda categórica del entrenamiento. Random Forest transforma las categorías en columnas binarias dentro de su flujo.

La codificación de Random Forest se ajusta solo con el conjunto de entrenamiento y una categoría no vista se representa con ceros; C4.5 conserva una rama por categoría. Esas diferencias de preprocesamiento son una posible fuente de sesgo en la comparación y se retoman al interpretar los resultados. Ambos modelos exponen el mismo contrato de predicción: reciben una tabla de datos, devuelven una columna con la clase predicha y conservan el índice y el orden de las filas sin modificar la entrada. La validación exige las mismas columnas y tipos del entrenamiento, y los desempates del árbol son deterministas. Las probabilidades del árbol son frecuencias ponderadas y no están calibradas.

4.2 Decisiones de diseño y problemas encontrados

Los principales problemas fueron el tratamiento de atributos continuos, los valores faltantes, el control del crecimiento y la comparabilidad del preprocesamiento. La Tabla 1 resume los tratamientos adoptados o previstos. Las pruebas de cortes, conservación de masa y repetición de particiones respaldan los tratamientos de mayor riesgo. El crecimiento se controla con cuatro parámetros independientes: el umbral de ganancia, la profundidad máxima, la masa mínima y la tasa de ganancia mínima; no se implementa pospoda.

Tabla 1. Problemas técnicos y tratamientos adoptados o previstos.

Problema	Tratamiento
Atributos continuos	Cortes binarios en valores observados; sin grilla global
Valores faltantes	Reparto proporcional en C4.5; mediana y moda de entrenamiento en Random Forest
Crecimiento	Prepoda con cuatro controles; sin pospoda
Preprocesamiento	Categorías nativas en C4.5; codificación binaria en Random Forest

5 Simulaciones y resultados

5.1 Datos, configuración y métricas

Los experimentos utilizan Contact Lenses, Iris y la versión procesada de Cleveland de Heart Disease. Lenses contiene 24 casos y cuatro atributos categóricos; Iris, 150 casos y cuatro medidas; Cleveland, 303 casos y trece atributos de ambos tipos [2]. En Cleveland se agrupan las clases originales de uno a cuatro como presencia y se conserva cero como ausencia: quedan 139 y 164 casos, respectivamente. Se conservan seis celdas faltantes de seis casos, cuatro en vasos y dos en thal. No se eliminan filas y ambos modelos reciben los mismos índices en cada partición.

Se reserva el 20 % de cada conjunto para prueba con estratificación y semilla 42. Para elegir parámetros se reserva además el 25 % del bloque de entrenamiento como validación, equivalente aproximadamente al 20 % del total. La grilla mínima compara profundidades de dos niveles o sin límite en C4.5 y 30 o 100 árboles en Random Forest; la elección utiliza F1 macro de validación y desempate por orden de configuración. Después se reentrena con todo el bloque inicial de entrenamiento y se evalúa en prueba. La referencia inicial y los barridos descriptivos no intervienen en esa elección.

Se calcula la tasa de acierto como cantidad de respuestas correctas dividida por casos evaluados. Para cada clase se calcula precisión, proporción correcta entre sus predicciones; exhaustividad, proporción detectada entre sus casos reales; y F1, su combinación armónica. Se informan promedios macro, con igual peso por clase, y ponderados por soporte; una división sin denominador se informa como cero. La Tabla 2 muestra la evaluación final y sus tiempos. El entrenamiento incluye la preparación y el aprendizaje; la inferencia incluye transformar y predecir, mientras que las métricas y la presentación quedan fuera de ambos cronómetros.

La batería de faltantes compara 0 %, 5 %, 15 % y 30 % nominales de ausencias adicionales, con tres máscaras de semillas 42, 43 y 44. Las mismas celdas se ocultan para ambos modelos y las etiquetas permanecen completas. El escenario cero conserva los faltantes naturales de Cleveland; no representa una tabla sin ausencias. Para limitar el costo del reparto fraccionario se fija profundidad seis y ganancia mínima 0,05 en C4.5; Random Forest conserva 100 árboles e imputación

por mediana y moda. Esas configuraciones permanecen iguales en los cuatro porcentajes y se distinguen de las elegidas por validación.

Tabla 2. Evaluación final con selección interna por validación.

Datos	Modelo	Acierto	F1 macro	Apr. (ms)	Pred. (ms)
Lenses	C4.5	1.000	1.000	2.0	0.7
Lenses	Random Forest	1.000	1.000	30.3	6.5
Iris	C4.5	0.933	0.933	150.0	1.3
Iris	Random Forest	0.933	0.933	35.6	5.2
Cleveland	C4.5	0.721	0.719	907.9	3.5
Cleveland	Random Forest	0.836	0.836	57.5	13.6

Tabla 3. Efecto de los faltantes adicionales: media entre tres máscaras.

Datos	Modelo	Acierto		F1 macro	
		0 %	30 %	0 %	30 %
Cleveland	C4.5	0.705	0.792	0.703	0.790
Cleveland	Random Forest	0.885	0.831	0.885	0.830
Iris	C4.5	0.933	0.800	0.933	0.803
Iris	Random Forest	0.900	0.878	0.900	0.878
Lenses	C4.5	1.000	0.533	1.000	0.230
Lenses	Random Forest	0.800	0.667	0.619	0.352

5.2 Resultados y sensibilidad

La Tabla 3 y la Figura 1 comparan el efecto de ocultar atributos con parámetros fijos. La tabla presenta los extremos y la figura incluye también 5 % y 15 %; los registros conservan todos los porcentajes observados. Las diferencias entre conjuntos no aíslan un efecto causal del tipo de atributo: cambian simultáneamente el problema, las clases y el tamaño. En Lenses, con cinco casos de prueba, un acierto modifica la tasa en veinte puntos porcentuales. Por ello, sus saltos no se interpretan como evidencia suficiente de superioridad general.

Los barridos varían un parámetro por vez con tres particiones estratificadas de semillas 42, 43 y 44, compartidas entre algoritmos. Se estudian profundidad, masa mínima, ganancia mínima, tasa de ganancia mínima y filtro experimental en C4.5; cantidad de árboles, atributos candidatos, profundidad, criterio y muestreo con reemplazo en Random Forest. La Figura 2 ilustra la relación entre ajuste y prueba al variar profundidad en Cleveland; la Figura 3 muestra el efecto de la cantidad de árboles. Las bandas o barras describen un desvío muestral entre particiones y no son intervalos de confianza. Estas curvas son descriptivas:

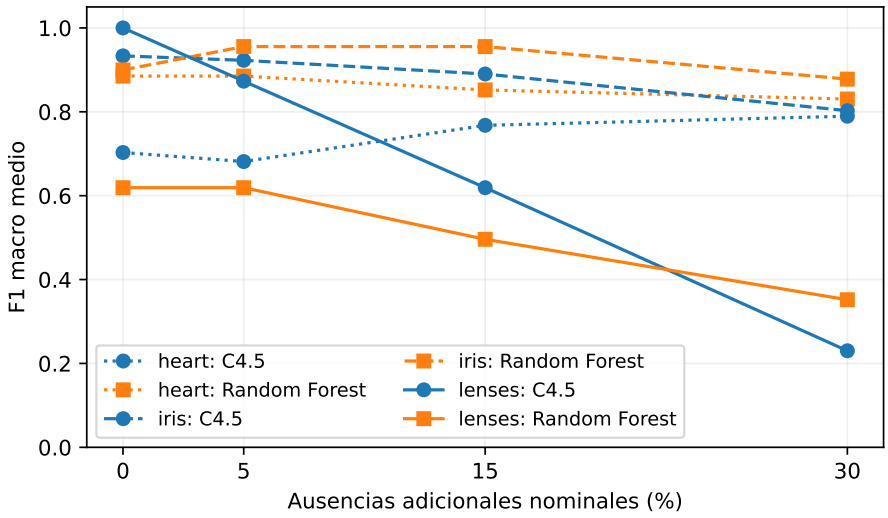


Figura 1. F1 macro medio en prueba frente a ausencias adicionales. El estilo de línea identifica el conjunto; el marcador distingue el modelo.

sus máximos no seleccionan un modelo ni se presentan como una evaluación independiente de una búsqueda.

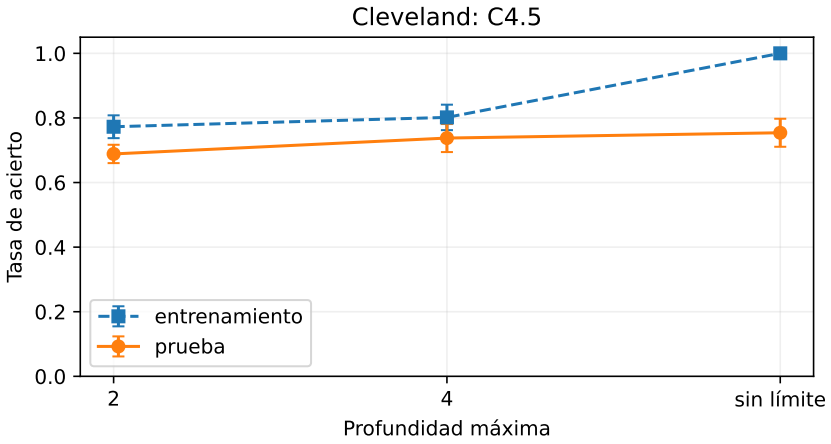


Figura 2. Cleveland: tasa de acierto en entrenamiento y prueba al variar la profundidad de C4.5.

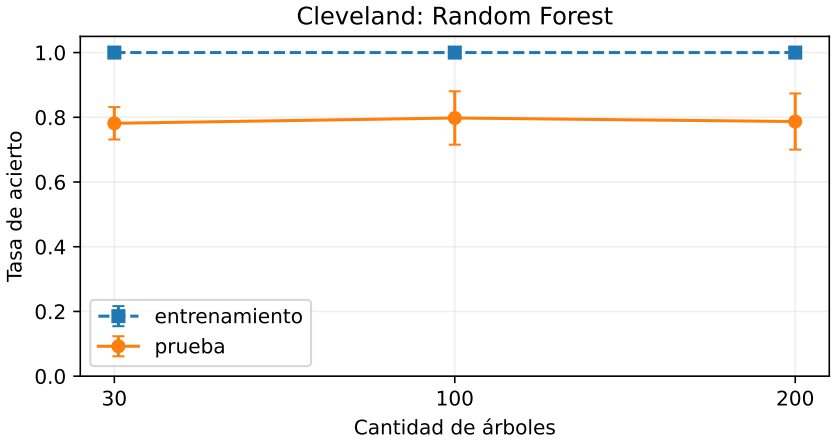


Figura 3. Cleveland: tasa de acierto al variar la cantidad de árboles del bosque.

Se conserva desactivado un filtro experimental de ganancia, que puede seleccionarse como variante. Si se activa, el corte numérico se elige por ganancia y solo compiten atributos de ganancia al menos media antes de comparar las tasas. Este cambio es una decisión experimental del trabajo: no se atribuye a una referencia que no se haya consultado ni se presupone que mejore el resultado. Sus dos condiciones se registran y se prueban de manera independiente, sin alterar la referencia inicial.

En Lenses, el F1 macro final es 1.000 para C4.5 y 1.000 para Random Forest. En Iris, el F1 macro final es 0.933 para C4.5 y 0.933 para Random Forest. En Cleveland, el F1 macro final es 0.719 para C4.5 y 0.836 para Random Forest. Estas cifras corresponden a la selección interna por validación; no al máximo de los barridos de prueba.

En Lenses, al pasar de cero a treinta por ciento de ausencias adicionales, C4.5 pasa de 1.000 a 0.230; Random Forest pasa de 0.619 a 0.352 de F1 macro medio. En Iris, al pasar de cero a treinta por ciento de ausencias adicionales, C4.5 pasa de 0.933 a 0.803; Random Forest pasa de 0.900 a 0.878 de F1 macro medio. En Cleveland, al pasar de cero a treinta por ciento de ausencias adicionales, C4.5 pasa de 0.703 a 0.790; Random Forest pasa de 0.885 a 0.830 de F1 macro medio. La comparación conserva parámetros y casos; no se supone que el efecto sea monótono ni que se repita en otros problemas.

En el barrido descriptivo de Cleveland, el árbol sin filtro obtiene 0.754 de tasa de acierto media, con desvío 0.043; con filtro obtiene 0.738, con desvío 0.043. Se informa la variante sin activarla por defecto. Ambas condiciones conservan los demás parámetros y las particiones. La comparación describe esta muestra y no selecciona el uso del filtro mediante los resultados de prueba.

6 Conclusiones

El trabajo entrega una implementación propia del árbol con tipos mixtos, pesos fraccionarios y controles de crecimiento, y una comparación con Random Forest bajo un protocolo común. La integración conserva los casos incompletos y aprende las transformaciones exclusivamente con entrenamiento. Las tablas separan la selección por validación de los barridos descriptivos, y distinguen ausencias naturales de las artificiales. La exportación automática evita transcribir cifras de una versión anterior de los modelos y permite repetir la comparación con los parámetros y semillas registrados.

Las observaciones anteriores corresponden a tres problemas pequeños y a las particiones medidas. La dispersión entre máscaras no estima la incertidumbre de cambiar de población, y la variación entre tres particiones no reemplaza un estudio más amplio. Los tiempos dependen del entorno y se informan como mediciones descriptivas, sin convertir pequeñas diferencias en conclusiones generales. El árbol ofrece reglas individuales que pueden inspeccionarse; el bosque combina decisiones de múltiples árboles, y esa diferencia de interpretación debe considerarse junto con las métricas del problema.

Se mantienen como ampliaciones la pospoda, la validación cruzada más extensa y las mediciones de tiempos bajo condiciones controladas. La revisión editorial final debe confirmar los datos personales de la portada y la ejecución completa de la versión integrada en Google Colab. Estas limitaciones se separan de la implementación y de los experimentos locales ya realizados.

Referencias

1. Breiman, L.: Random forests. Machine Learning **45**(1), 5–32 (2001). https://doi.org/10.1023/A:1010933404324
2. Janosi, A., Steinbrunn, W., Pfisterer, M., Detrano, R.: Heart disease. UCI Machine Learning Repository (1989). https://doi.org/10.24432/C52P4X
3. Liu, B.: Web Data Mining: Exploring Hyperlinks, Contents, and Usage Data. Data-Centric Systems and Applications, Springer, Berlin, Heidelberg, 2 edn. (2011). https://doi.org/10.1007/978-3-642-19460-3
4. scikit-learn developers: Imputation of missing values. `https://scikit-learn.org/stable/modules/impute.html`, accessed 2026-11-08
5. scikit-learn developers: Random forests. `https://scikit-learn.org/stable/modules/ensemble.html#forest`, accessed 2026-10-15