Estudio comparativo del rendimiento de un árbol de decisión C4.5 propio y del modelo de ensamble Random Forest en problemas de clasificación

Laura Cornaló Bassan[1 [00000]], Matías Fernandez[1 [24282]], Mariano Insaurralde[1 [24684]], Philippe Maurel Garcete[1 [25613]], and Franco Sanchez[1 [27310]]

Universidad Tecnológica Nacional, Facultad Regional de Resistencia
Ingeniería en Sistemas de Información
{correo1,correo2,correo3,correo4,correo5}@gmail.com

Abstract. Keywords: Decision Tree · C4.5 · Random Forest

1 Introducción

Un clasificador automático asigna una clase a cada caso a partir de sus características. Los árboles de decisión resuelven esta tarea mediante una secuencia de preguntas sobre esas características y producen un modelo que una persona puede leer. C4.5 es uno de los algoritmos más difundidos de la familia: elige cada pregunta con un criterio orientado a separar las clases, acepta atributos numéricos y categóricos, tolera datos faltantes e incorpora mecanismos para frenar el crecimiento del árbol y evitar que se ajuste en exceso al conjunto de entrenamiento [2]. Cada camino de la raíz a una hoja equivale a una regla del tipo "si se cumple tal condición, se predice tal clase", de modo que las decisiones del modelo pueden explicarse y revisarse sin herramientas adicionales.

Un árbol aislado es sensible a pequeños cambios en los datos: agregar o quitar unos pocos casos de entrenamiento puede dar una estructura distinta. Random Forest (bosque aleatorio) atenúa este problema entrenando muchos árboles y combinando sus respuestas. Cada árbol se construye con una muestra aleatoria de los casos y, en cada división, evalúa solo un subconjunto al azar de las características; la clase final es la más votada entre todos los árboles. Así se diluye el peso de los casos atípicos y de los atributos dominantes, y por lo general la precisión mejora y las predicciones se vuelven más estables. A cambio, el cómputo es más costoso y una decisión individual deja de poder seguirse en una única regla, lo que explica que se lo describa como un modelo de caja negra [1].

Ninguno de los dos enfoques domina al otro en general. Si el problema es sencillo o hay que justificar cada decisión, un árbol puede bastar; si lo que importa es la precisión y no se exige explicar casos individuales, el bosque suele ser la opción más razonable. Ahora bien, la comparación solo es válida si ambos modelos se entrenan y prueban sobre las mismas particiones, se miden con las

mismas métricas y ninguno accede a información del conjunto de prueba durante el entrenamiento. Con esquemas de evaluación distintos, una diferencia de rendimiento puede reflejar la forma de medir y no el algoritmo.

Este trabajo realiza esa comparación sobre el conjunto de datos [DATASET PENDIENTE]. Se implementa desde cero un árbol de decisión basado en C4.5 y se lo contrasta con el Random Forest de scikit-learn [3]. Programar el árbol propio permite controlar y justificar cada decisión de construcción, mientras que el bosque de scikit-learn sirve de referencia de un método de ensamble de uso extendido. Los dos modelos se evalúan con las mismas particiones y métricas, y para cada uno se prueban varias configuraciones de parámetros con el fin de ver cómo responde su comportamiento.

El objetivo es determinar en qué condiciones conviene cada modelo, atendiendo a la precisión, pero también a la estabilidad de las predicciones, al tiempo de cómputo y a qué tan interpretable resulta cada uno. El diseño experimental busca que las diferencias observadas puedan atribuirse a los algoritmos y no a las condiciones de la prueba. De fondo está la idea de que la mayor complejidad de un bosque no garantiza una mejora: esta depende del problema, de la métrica que se priorice y del costo que se acepte pagar.

Las contribuciones son una implementación propia de C4.5, con decisiones explícitas sobre la construcción, el criterio de división y el control del crecimiento del árbol [2]; un esquema de evaluación común para ambos modelos; y un análisis comparativo de los cuatro aspectos mencionados, que puede orientar la elección entre árbol y bosque en problemas similares.

El resto del trabajo se organiza así: la sección 2 expone los fundamentos teóricos de C4.5 y Random Forest; la sección 3 describe brevemente los algoritmos desarrollados; la sección 4 presenta la solución implementada y los problemas encontrados; la sección 5 reúne las simulaciones y sus resultados; y la sección 6 discute las conclusiones. Las referencias cierran el documento.

2 Fundamentos teóricos

2.1 Árboles de decisión y C4.5

2.2 Random Forest

3 Breve descripción de los algoritmos desarrollados

4 Solución implementada

5 Simulaciones y resultados

6 Conclusiones

References

1. Breiman, L.: Random forests. Machine Learning **45**(1), 5–32 (2001). https://doi.org/10.1023/A:1010933404324

2. Liu, B.: Web Data Mining: Exploring Hyperlinks, Contents, and Usage Data. Data-Centric Systems and Applications, Springer, Berlin, Heidelberg, 2 edn. (2011). https://doi.org/10.1007/978-3-642-19460-3
3. scikit-learn developers: Random forests. `https://scikit-learn.org/stable/modules/ensemble.html#forest`, accessed 2026-10-15